

三節路線：技術全貌、儲存整合、處理與呈現

技術的工作，是讓資料可靠地走到決策

第一節

資料與技術全貌

第二節

儲存與整合

第三節

處理、分析與呈現

本週不寫程式，重點是看懂資料在系統中的旅程

從業務問題到技術流程

第一節 02/11

01

來源

交易與客服

02

整合

清理並接系統

03

儲存

資料與歷史

04

處理

依時限完成

05

使用

分析與決策

技術選擇必須配合問題、資料與時限

結構化

欄列固定，例如交易表與客戶資料表

半結構化

有標記但結構可變，例如 JSON 與系統紀錄

非結構化

沒有固定欄列，例如客服文字、語音與影像

資料型態會影響儲存、搜尋與分析方式

優點

- 欄位清楚，容易查詢
- 適合彙總、比較與報表
- 品質規則較容易建立

常見問題

- 不同系統欄位定義不一致
- 代碼或日期格式不同
- 資料表之間缺少共同識別

常見形式

JSON、XML、事件紀錄與 API 回應

結構特色

保留欄位標記，但每筆內容可能不同

金融例子

App 操作事件、系統登入紀錄與服務訊息

處理重點

解析欄位、統一時間與確認版本

常見形式

文字、文件、錄音、影像與影片

金融例子

客服對話、申訴文件、新聞與法說內容

分析難點

內容需要轉換，語意也容易受情境影響

使用要求

先確認目的、權限、隱私與品質

批次 Batch

- 累積一段時間後集中處理
- 適合日報、月報與歷史分析
- 可在非尖峰時間執行

即時 Streaming

- 事件到達後快速處理
- 適合交易監測與即時提醒
- 更重視穩定性與反應時間

資料來源與用途的配對

第一節 08/11

交易資料	報表、關聯分析、異常交易監測
------	----------------

客戶資料	服務分析、客戶分群與風險判斷
------	----------------

系統紀錄	資安監測、效能與操作流程改善
------	----------------

文字資料	客服議題、新聞與研究內容分析
------	----------------

產生

刷卡系統收到金額、商店、時間與裝置

整合

接上帳戶狀態與歷史交易模式

處理

即時計算風險，必要時要求再次驗證

保存

留下交易與處置紀錄，供後續分析

即時判斷與歷史分析會使用不同處理節奏

型態

結構化、半結構化與非結構化

來源

交易、客戶、系統與外部資訊

速度

批次處理與即時處理各有用途

選擇

技術必須配合問題、資料型態與時限

本節搶答題

第一節 11/11

5 分鐘 | 先作答，再核對答案

1. 交易資料表通常屬於哪一類？（ A 結構化 B 非結構化 ）
2. 客服錄音通常屬於哪一類？（ A 半結構化 B 非結構化 ）
3. JSON 較接近哪一類？（ A 半結構化 B 紙本資料 ）
4. 月底報表較適合哪種處理？（ A 批次 B 即時 ）
5. 詐欺交易當下判斷較重視什麼？（ A 反應時間 B 投影片數 ）

答案：1-A 2-B 3-A 4-A 5-A

不同資料放在哪裡，取決於用途與管理方式

作業資料庫

支援日常交易

資料倉儲

支援整合分析

資料市集

聚焦部門需求

資料湖

保留多樣原始資料

主要用途

支援存款、轉帳、下單與理賠等日常作業

資料特色

記錄最新狀態，更新頻繁且要求正確

設計重點

快速寫入、交易一致與系統穩定

分析限制

跨系統與長期趨勢分析通常較不方便

把分散資料整理成可分析的共同版本

資料倉儲通常整合多個內部系統，保留歷史並提供報表、商業智慧與分析使用。

資料倉儲的四個特性

第二節 04/11

主題導向

依客戶、商品或風險等分析主題組織

整合性

統一來源系統的欄位、代碼與定義

長期性

保留歷史，才能比較變化與趨勢

少變性

資料載入後以查詢與分析為主要用途

定位	聚焦一個部門、主題或特定分析需求
----	------------------

例子	信用風險市集、行銷市集或理賠市集
----	------------------

優點	範圍較小，較容易貼近使用者需求
----	-----------------

風險	各自建置可能形成重複與不一致
----	----------------

定位	以較原始形式保留大量、多樣資料
可放內容	表格、系統紀錄、文件、文字與影像
優點	保留彈性，便於未來不同分析需求
風險	缺少目錄與治理時，資料會難以尋找與信任

四種儲存方式的用途

第二節 07/11

作業資料庫	處理今天正在發生的交易
-------	-------------

資料倉儲	整合歷史資料並支援共同分析
------	---------------

資料市集	服務特定部門或主題
------	-----------

資料湖	保留多樣、較原始的資料
-----	-------------

實務上可能並存，不必硬選唯一一種

01

Extract

從來源擷取

02

Transform

清理並統一

03

Load

載入分析環境

ETL 的重點是讓不同來源能以共同定義使用

ELT 則先載入，再於目標環境轉換

共同識別

不同系統是否指向同一客戶或帳戶？

共同時間

交易時間、入帳時間與報表日期是否一致？

共同定義

『活躍客戶』在各部門是否相同？

追蹤來源

數字從哪裡來？經過哪些轉換？

作業資料庫	支援日常交易與最新狀態
資料倉儲	整合歷史資料供分析
資料市集	服務特定主題與部門
資料湖	保留多樣原始資料
整合治理	統一識別、時間、定義與來源

本節搶答題

第二節 11/11

5 分鐘 | 先作答，再核對答案

1. 支援即時轉帳最接近哪一種？（ A 作業資料庫 B 資料市集 ）
2. 長期趨勢分析較常使用什麼？（ A 資料倉儲 B 暫存檔 ）
3. 只服務理賠部門的資料集合較接近？（ A 資料市集 B 作業系統 ）
4. 資料湖缺少治理時最可能發生什麼？（ A 難以尋找與信任 B 自動變乾淨 ）
5. ETL 的 T 代表什麼？（ A Transform B Transfer ）

答案：1-A 2-A 3-A 4-A 5-A

資料規模增加時，單一電腦可能不再足夠

分散式儲存

資料分開保存

分散式處理

工作分開計算

雲端服務

依需要取得資源

分析呈現

把結果交給使用者

把資料與工作分給多台電腦

系統再把各部分結果彙整。這種方式能處理更大規模，也能透過副本降低單一設備故障的影響。

Hadoop 的歷史角色

第三節 03/11

背景

大量網頁與非結構化資料促成分散式需求

定位

開放原始碼的分散式儲存與處理生態

代表概念

HDFS 分散儲存，MapReduce 分散計算

今天的理解

保留核心觀念，不把它視為唯一現代方案

HDFS 的直覺

第三節 04/11

01

切割

大型檔案分成區塊

02

分散

區塊存到多台設備

03

副本

重要資料保留多份

04

讀取

系統協調並組回需要
內容

重點：容量可擴充，也能降低單點故障風險

MapReduce 的直覺

第三節 05/11

01

Map

把工作拆成多份並行計算

02

Shuffle

把相同類型結果整理到一起

03

Reduce

彙整成最後結果

例：不同電腦先統計各分店交易，再彙總全行結果

資源取得

依需求使用運算、儲存與平台服務

彈性

工作量增加時可調整資源

管理

由服務提供者處理部分基礎設施工作

責任

組織仍需管理權限、資料安全與成本

批次分析

- 日終或月底集中處理
- 適合完整報表與歷史趨勢
- 允許較長處理時間

即時分析

- 事件進入後立即處理
- 適合交易監測與系統告警
- 要求低延遲與穩定運作

查詢

依條件找出資料與彙總結果

商業智慧

以報表與儀表板掌握營運狀況

資料探勘

找出分群、關聯、分類與預測模式

模型服務

把分析結果接回實際作業流程

比較

長條圖呈現類別差異

趨勢

折線圖呈現時間變化

關係

散佈圖呈現兩個數值的關係

原則

先確認讀者與問題，再選圖表

圖表的工作是縮短理解時間，不是增加裝飾

資料型態

決定儲存與處理方式

儲存整合

讓分散資料形成共同版本

分散與雲端

支援更大規模與彈性資源

分析呈現

把資料轉成可理解、可使用的結果

選擇原則

配合問題、時限、安全與成本

本節搶答題

第三節 11/11

5 分鐘 | 先作答，再核對答案

1. HDFS 的核心概念較接近？（ A 分散儲存 B 圖表美化 ）
2. MapReduce 的 Map 主要做什麼？（ A 拆分並行工作 B 最後彙整 ）
3. 使用雲端後，組織是否仍需管理權限與安全？（ A 需要 B 不需要 ）
4. 呈現時間趨勢通常適合什麼圖？（ A 折線圖 B 圓餅圖 ）
5. 選擇技術時最重要的是？（ A 配合問題與時限 B 名稱最新 ）

答案：1-A 2-A 3-A 4-A 5-A