

本週路線

相似性與資料準備、K-means、選 K 與解讀

學習目標

能說明分群原理，並判斷結果是否合理

銜接

本週學方法，下一週完成客戶分群案例

集群分析 Clustering

第一節 02/11

核心問題

哪些對象彼此相似？

分析方式

依選定特徵衡量相似程度

資料狀態

沒有預先指定的正確群別

結果工作

演算法分群，人員解讀群組意義

分群的核心概念

第一節 03/11

同一群內

成員在選定特徵上較相似

不同群間

各群的特徵輪廓應有差異

非監督式

資料中沒有預先指定的答案

需要解讀

分群不代表成員完全相同

相似來自選定的特徵

第一節 04/11

交易行為

交易次數、金額與常用管道

產品往來

持有商品數、使用程度與期間

服務互動

客服頻率、等待時間與數位操作

風險表現

逾期、波動或異常交易特徵

資料列 Rows	通常代表客戶、交易或案件
----------	--------------

分群對象	K-means 把資料列分成群組
------	------------------

資料欄 Columns	代表用來比較的特徵
-------------	-----------

重要原則	分析單位一致，欄位定義清楚
------	---------------

距離較小

通常表示兩筆資料較相似

計算基礎

K-means 常使用數值特徵

解讀範圍

距離只反映已納入的欄位

未納入資訊

不會影響演算法的分群結果

年交易金額

數值可能以萬元計算

每月登入次數

數值可能只有個位數

未經處理

範圍大的欄位容易主導距離

標準化

把不同尺度轉成較可比較的範圍

分群前的資料準備

第一節 08/11

分析單位

一列代表同一種對象

欄位品質

處理缺漏、錯誤與極端值

數值特徵

確認欄位能合理計算距離

尺度處理

需要時進行標準化

分群可以支援的工作

第一節 09/11

客戶經營

依往來型態設計不同服務方式

產品研究

找出具有相似表現的商品

營運管理

辨識相似分行、通路或案件

風險探索

觀察異常群組，再交由人員查核

分群目的	群內較相似，群間有所差異
------	--------------

非監督式	沒有預先指定的正確群別
------	-------------

特徵選擇	決定演算法如何理解相似
------	-------------

資料準備	先處理品質與尺度問題
------	------------

本節搶答題

第一節 11/11

5 分鐘 | 先作答，再核對答案

1. 集群分析通常屬於？（ A 非監督式 B 監督式 ）
2. 同群成員是否必須完全相同？（ A 必須 B 不必 ）
3. 特徵選擇會影響結果嗎？（ A 會 B 不會 ）
4. 尺度差異過大時可考慮？（ A 標準化 B 隨意刪除 ）
5. 分群結果由誰解讀？（ A 人員 B 演算法保證 ）

答案：1-A 2-B 3-A 4-A 5-A

第二節 | K-means 的運作方式

第二節 01/11

核心循環

設定 K、分配資料、更新質心

學習重點

理解演算法如何反覆改善群組

課堂原則

掌握直覺，不手算大量距離表

K 與質心 Centroid

第二節 02/11

K 預先指定要分成幾個群

質心 一群資料在各特徵上的平均位置

初始質心 演算法開始時的 K 個中心

分群依據 每筆資料歸入距離最近的質心

K-means 四步循環

第二節 03/11

第一步

選擇 K 與初始質心

第二步

計算每筆資料到各質心的距離

第三步

放入最近質心所代表的群

第四步

重算質心，再次進行分配

第一步：設定 K

第二節 04/11

業務需求

組織能否合理服務這麼多群？

資料結構

資料是否呈現可分辨的群組？

比較方案

嘗試不同 K，再比較結果

避免極端

K 太小過度合併，太大難以管理

第二步：選初始質心

第二節 05/11

初始位置	演算法先放置 K 個起始中心
常見方式	可隨機選擇或使用穩定初始化
可能影響	不同起點可能得到不同結果
實務做法	多次執行並比較，降低偶然性

第三步：計算距離

第二節 06/11

平面直覺

兩個數值特徵可想成平面上的點

多個特徵

維度增加，判斷原則仍相同

分配規則

尋找距離最近的質心

前提

不同尺度的欄位要先妥善處理

距離的簡單例子

第二節 07/11

客戶甲

月交易 2 次，平均金額 3 千元

質心一

月交易 3 次，平均金額 4 千元

質心二

月交易 10 次，平均金額 12 千元

分配

若甲較接近質心一，就歸入第一群

第四步：更新質心

第二節 08/11

暫時群組

每筆資料已分配到最近的群

重新平均

計算群內各特徵的平均值

移動質心

新的平均位置成為下一輪中心

再次分配

所有資料重新尋找最近質心

何時停止反覆計算

第二節 09/11

群別穩定

資料所屬群組不再改變

質心穩定

中心位置只剩很小變化

達到上限

執行到預先設定的最多次數

完成後

保存群別與質心供後續解讀

設定	先指定群組數 K 與初始質心
----	------------------

分配	依距離把資料放入最近的群
----	--------------

更新	重新計算每一群的質心
----	------------

反覆	直到群別或質心大致穩定
----	-------------

本節搶答題

第二節 11/11

5 分鐘 | 先作答，再核對答案

1. K 代表什麼？（ A 群數 B 欄位數 ）
2. 質心代表？（ A 群內平均位置 B 群名 ）
3. 資料分到哪一群？（ A 最近質心 B 最遠質心 ）
4. 更新質心後是否重新分配？（ A 要 B 不用 ）
5. 不同初始質心可能造成？（ A 結果不同 B 一定相同 ）

答案：1-A 2-A 3-A 4-A 5-A

品質判斷

群內集中，群間具有差異

業務判斷

群組說得通，也能支援行動

責任

說明限制，避免把群別當成固定標籤

群內誤差平方和 SSE

第三節 02/11

計算概念

各資料點到所屬質心的距離平方加總

數值較小

通常表示群內資料較集中

平方作用

消除正負方向並加重較大距離

使用限制

SSE 不能單獨決定最佳 K

K 增加時，SSE 通常下降

第三節 03/11

K 較小	少數群組容納差異較大的成員
------	---------------

K 增加	每群範圍縮小，距離通常下降
------	---------------

極端情況	每筆資料各成一群，SSE 很小
------	-----------------

判斷重點	不能只追求最低 SSE
------	-------------

肘部法 Elbow Method

第三節 04/11

橫軸

群數 K

縱軸

群內誤差平方和 SSE

觀察方式

尋找下降開始趨緩的轉折附近

限制

沒有明顯轉折時要搭配其他判斷

K 值的綜合判斷

第三節 05/11

統計表現

群內是否集中，結果是否穩定？

群組規模

是否出現極小群或空群？

可解釋性

各群差異是否清楚？

可行動性

組織能否對不同群採取做法？

群組大小

每一群有多少客戶或案件？

中心特徵

各群在主要特徵上的高低

差異來源

哪些欄位最能區分不同群？

代表案例

接近質心的成員協助理解

群組命名的原則

第三節 07/11

依據資料

根據可核對的特徵描述

清楚具體

例如高頻數位往來群

避免貼標籤

不用人格或價值判斷命名

保留差異

同群成員仍可能有個別不同

K-means 的主要限制

第三節 08/11

適用資料

主要處理可計算平均的數值特徵

群組形狀

不規則群組可能分得不好

極端值

離群資料可能拉動質心

初始敏感

不同起點可能得到不同結果

用途限定

結果只用於事先說明的目的

公平檢查

避免不合理的差異待遇

人工覆核

高影響決定不能只依群別

持續更新

客戶行為改變後重新評估

分群基礎

用選定特徵衡量相似

K-means

設定 K、分配、更新並反覆進行

選擇 K

結合 SSE、穩定性與業務需求

結果使用

描述輪廓，同時說明限制

本節搶答題

第三節 11/11

5 分鐘 | 先作答，再核對答案

1. SSE 較小通常表示？ (A 群內較集中 B K 一定最佳)

2. K 增加時 SSE 通常？ (A 下降 B 上升)

3. 肘部法觀察？ (A 下降趨緩轉折 B 最大群名)

4. 群名是否等於客戶本質？ (A 是 B 否)

5. K-means 是否適合所有資料？ (A 是 B 否)

答案：1-A 2-A 3-A 4-B 5-B