

本週問題

如何依歷史資料判斷新對象的類別

學習主線

分類任務、樹狀結構、分割規則與驗證

學習目標

能沿著決策樹說明一次判斷

金融連結

回購、流失、風險與案件分類

分類 Classification

第一節 02/11

已知資料

每筆歷史資料已有正確類別

學習目的

找出特徵與類別之間的判斷規則

新資料

依規則預測尚未知道的類別

常見結果

是或否、高或低、多個風險等級

監督訊號

歷史資料中的目標欄位

目標欄位

例如是否回購、是否流失

輸入特徵

年齡、交易行為、服務使用紀錄

核心前提

訓練資料必須同時具有特徵與答案

分群與分類的差異

第一節 04/11

分群

事前沒有指定正確群別

分類

事前已知要預測的目標類別

分群問題

哪些客戶彼此相似

分類問題

這位客戶屬於哪一類

外觀	由上往下形成樹狀判斷流程
----	--------------

每次判斷	根據一個特徵把資料分開
------	-------------

最後結果	落在某個葉節點並得到類別
------	--------------

主要優點	判斷路徑可用白話解釋
------	------------

樹根、節點、分枝與葉子

第一節 06/11

樹根 Root	全部資料開始判斷的位置
---------	-------------

節點 Node	檢查某個特徵或條件
---------	-----------

分枝 Branch	條件成立或不成立的路徑
-----------	-------------

葉節點 Leaf	停止分割後給出的預測類別
----------	--------------

目標

客戶是否在三個月內回購

特徵一

最近一次消費距今天數

特徵二

過去一年消費次數

特徵三

是否使用優惠或完成會員互動

沿著樹做一次判斷

第一節 08/11

第一個節點	最近消費是否在 30 天內
-------	---------------

符合條件	再看過去一年消費次數
------	------------

不符合條件	走到另一條分枝
-------	---------

葉節點	得到可能回購或可能不回購
-----	--------------

決策樹為何容易解釋

第一節 09/11

判斷透明

每個節點都有明確條件

路徑可追

可列出個案經過哪些分枝

可轉成規則

條件組合可寫成如果與那麼

限制

容易解釋不代表一定正確或公平

分類任務

以已知類別學習判斷規則

決策樹結構

樹根、節點、分枝與葉子

預測方式

新資料沿著條件一路走到葉節點

使用價值

能呈現個別判斷的主要路徑

本節搶答題

第一節 11/11

5 分鐘 | 先作答，再核對答案

1. 分類是否需要已知目標類別？(A 要 B 不用)
2. 分群與分類是否相同？(A 相同 B 不同)
3. 樹的最終結果位於？(A 葉節點 B 樹根)
4. 新資料如何得到預測？(A 沿分枝前進 B 隨機抽籤)
5. 決策樹容易解釋是否代表一定正確？(A 是 B 否)

答案：1-A 2-B 3-A 4-A 5-B

第二節 | 決策樹如何形成

第二節 01/11

核心問題

哪一個特徵最能把不同類別分開

建樹方式

選擇分割、形成子群、繼續分割

停止條件

資料夠純、樣本太少或深度達上限

分割之前

不同類別混在同一群資料中

分割之後

每一側盡量集中相同類別

判斷原則

分割後的不純度要明顯下降

效果

後續分類更清楚，規則也較容易理解

純度高

節點中的資料大多屬於同一類

純度低

不同類別混合在一起

建樹目標

逐次降低子節點的不純度

注意

完全純淨可能只是過度配合訓練資料

Entropy 的直覺

第二節 04/11

用途

衡量類別混合程度

單一類別

Entropy 較低

類別接近平均

Entropy 較高

教學重點

理解方向即可，不要求複雜推導

計算概念

比較分割前後的 Entropy

增益較大

代表分割後類別更集中

選擇方式

優先採用資訊增益較大的特徵

限制

仍需配合樣本數與停止規則

用途

另一種衡量類別混合程度的方法

數值較低

節點中的類別較集中

常見使用

許多決策樹工具可選用 Gini

課堂原則

Entropy 與 Gini 都是在比較分割品質

連續數值如何分割

第二節 07/11

範例特徵

最近消費距今天數

候選切點

例如 30 天或 60 天

比較方式

檢查每個切點能否把類別分得更清楚

最後選擇

採用改善不純度較多的切點

類別特徵如何分割

第二節 08/11

範例特徵

主要交易通路

可能類別

分行、網銀或行動銀行

分割方式

依工具規則形成兩個或多個分枝

前處理

類別名稱與缺失值必須先整理

停止生長的條件

第二節 09/11

最大深度

限制樹可以長到幾層

最小樣本

節點樣本太少時不再分割

改善門檻

分割帶來的改善不足時停止

目的

降低模型複雜度並保留可解釋性

選擇特徵

找出最能降低不純度的分割

常見指標

Entropy、Information Gain 與 Gini

連續特徵

需要選擇適當切點

停止條件

避免樹一直生長並記住個別樣本

本節搶答題

第二節 11/11

5 分鐘 | 先作答，再核對答案

1. 好的分割會讓類別？（ A 更集中 B 更混亂 ）
2. Entropy 用來衡量？（ A 混合程度 B 交易金額 ）
3. 資訊增益較大代表？（ A 分割改善較多 B 樣本較少 ）
4. 連續特徵是否需要切點？（ A 要 B 不用 ）
5. 停止條件可否避免樹無限生長？（ A 可以 B 不可以 ）

答案：1-A 2-A 3-A 4-A 5-A

訓練不是終點

模型還要接受未看過資料的檢驗

主要風險

樹太深會產生過度配適

實務要求

同時檢查效能、解釋與使用後果

訓練集

用來建立決策樹

測試集

建樹時不使用，最後用來檢驗

分開目的

模擬模型面對新資料的表現

重要原則

不可先看測試答案再調整規則

混淆矩陣

第三節 03/11

真正例 True
Positive

實際為是，模型也判斷為是

真反例 True
Negative

實際為否，模型也判斷為否

偽陽性 False
Positive

實際為否，模型判斷為是

偽陰性 False
Negative

實際為是，模型判斷為否

Accuracy

所有判斷中正確的比例

類別失衡

大多數都屬於同一類時可能誤導

金融情境

漏掉高風險與誤報的成本不同

評估原則

依使用目的選擇適合的指標

過度配適 Overfitting

第三節 05/11

表現特徵

訓練資料很好，測試資料明顯較差

常見原因

樹太深、葉節點樣本太少

結果

模型記住歷史細節，無法推廣

處理方向

限制生長或進行剪枝

剪枝 Pruning

第三節 06/11

概念

移除貢獻有限的分枝

目的

讓樹更簡單並改善新資料表現

代價

過度剪枝可能漏掉重要差異

選擇方式

用驗證結果比較不同樹的表現

目標類別

是否發生逾期

可能特徵

負債比、繳款紀錄與收入穩定度

模型輸出

預測類別與判斷路徑

使用限制

模型支援審查，不取代法規與人工判斷

目標類別

未來三個月是否流失

可能特徵

交易頻率、服務事件與產品持有變化

可能行動

改善服務或提供適當協助

限制

不可把預測直接當成客戶意圖

敏感特徵

需確認是否適合用於決策

代理變數

一般欄位也可能間接反映敏感身分

定期檢查

比較不同群體的錯誤率與影響

責任

保留資料來源、版本與人工覆核紀錄

分類基礎

以已知目標類別學習規則

建樹原理

每次選擇能降低不純度的分割

模型檢驗

使用測試資料與混淆矩陣

實務使用

控制過度配適並檢查公平與責任

本節搶答題

第三節 11/11

5 分鐘 | 先作答，再核對答案

1. 測試集是否用來建立樹？ (A 是 B 否)
2. 偽陽性代表實際否但預測是嗎？ (A 是 B 否)
3. 只看正確率是否總是足夠？ (A 是 B 否)
4. 剪枝主要為了？ (A 簡化模型 B 增加欄位)
5. 金融模型是否仍需人工覆核？ (A 需要 B 不需要)

答案：1-B 2-A 3-B 4-A 5-A