

本週任務

用已建立的決策樹判斷未知資料

學習主線

資料切分、模型訓練、測試評估與預測

學習目標

能說明一筆新資料如何得到預測

金融連結

客戶價值、回購與風險分類

從已知走向未知

第一節 02/11

過去資料

同時具有特徵與正確類別

模型學習

從歷史資料建立判斷規則

未知資料

只有特徵，尚未知道實際類別

模型輸出

提供預測類別與判斷依據

第一階段	定義目標欄位與輸入特徵
------	-------------

第二階段	切分訓練資料與測試資料
------	-------------

第三階段	建樹並評估測試結果
------	-----------

第四階段	通過檢驗後預測新資料
------	------------

目標類別

高貢獻或低貢獻客戶

R Recency

距離最近一次交易的時間

F Frequency

一定期間內的交易次數

M Monetary

一定期間內的交易金額

目標變數與自變數

第一節 05/11

目標變數 y	模型要學習與預測的類別
----------	-------------

自變數 X	提供判斷資訊的特徵欄位
---------	-------------

案例 y	客戶價值為高或低
--------	----------

案例 X	R、F、M 與其他適當欄位
--------	---------------

資料切分的目的

第一節 06/11

訓練資料

讓模型看見特徵與答案並建立規則

測試資料

保留到最後檢驗模型

避免問題

不能用同一批資料同時訓練又宣稱驗證

實務效果

較接近模型面對新客戶的情境

75% 與 25% 範例

第一節 07/11

訓練集 75%	用來建立決策樹
---------	---------

測試集 25%	用來計算模型表現
---------	----------

比例性質	這是常見示例，並非固定答案
------	---------------

真正考量	資料量、類別比例與時間順序
------	---------------

隨機切分與時間切分

第一節 08/11

隨機切分

資料順序沒有重要時間意義時可使用

時間切分

用較早資料訓練，較晚資料測試

金融情境

預測未來時通常要尊重時間順序

避免洩漏

未來資訊不可進入訓練特徵

先做簡單模型

限制深度並保留可解釋性

記錄設定

保存特徵、切分方式與參數

建立基準

後續修改要與同一測試標準比較

課堂原則

先確認流程正確，再追求更高分數

X 與 y

自變數提供資訊，目標變數提供答案

資料切分

訓練集建模，測試集評估

時間觀念

預測未來時要避免使用未來資料

下一步

先驗證模型，再交付未知資料預測

本節搶答題

第一節 11/11

5 分鐘 | 先作答，再核對答案

1. 目標變數通常記為？ (A y B X)
2. 測試集主要用來？ (A 建樹 B 評估)
3. 預測未來時能否使用未來資訊？ (A 能 B 不能)
4. 75% 與 25% 是否固定答案？ (A 是 B 否)
5. 模型通過測試後才適合預測新資料嗎？ (A 是 B 否)

答案：1-A 2-B 3-B 4-B 5-A

評估問題

模型在未看過的測試資料上表現如何

解釋問題

哪些特徵與條件形成主要判斷路徑

使用原則

分數與解釋要同時檢查

模型預測

每筆測試資料得到一個類別

實際答案

測試資料原本保留的正確類別

逐筆比較

形成正確與錯誤的四種情況

彙整工具

使用混淆矩陣呈現結果

真正例 TP

實際為高，預測也為高

真反例 TN

實際為低，預測也為低

偽陽性 FP

實際為低，預測為高

偽陰性 FN

實際為高，預測為低

Accuracy 正確率

第二節 04/11

計算概念

正確預測筆數除以全部測試筆數

優點

容易理解並可快速比較模型

限制

類別比例不均時可能過度樂觀

使用方式

搭配混淆矩陣與錯誤成本解讀

Precision 精確率

第二節 05/11

關心問題

模型判定為正類時，有多少是真的

適合情境

誤報會造成較高成本

金融例子

把低風險客戶誤判為高風險

提醒

提升 Precision 可能影響其他指標

關心問題

所有實際正類中，模型找出了多少

適合情境

漏掉正類會造成較高成本

金融例子

漏掉真正的異常交易

取捨

提高 Recall 可能增加誤報

常見狀況

異常交易通常只占少數

表面高分

全部預測正常也可能有高 Accuracy

實際問題

模型完全沒有找到重要少數類別

處理原則

看混淆矩陣、Precision 與 Recall

分割條件	某個特徵是否小於或等於門檻
------	---------------

<code>samples</code>	到達該節點的樣本數
----------------------	-----------

<code>value</code>	各類別在節點中的數量
--------------------	------------

<code>class</code>	該節點目前預測的主要類別
--------------------	--------------

解釋一條預測路徑

第二節 09/11

起點

從樹根檢查第一個條件

每一層

依新資料的特徵值選擇分枝

終點

到葉節點取得預測類別

白話說明

把沿途條件整理成一組如果與那麼規則

模型評估

以測試資料比較預測與實際答案

主要工具

混淆矩陣與 Accuracy

錯誤取捨

依情境同時看 Precision 與 Recall

模型解釋

沿著節點條件說明個案路徑

本節搶答題

第二節 11/11

5 分鐘 | 先作答，再核對答案

1. 混淆矩陣比較什麼？（ A 預測與實際 B 金額與日期 ）
2. Accuracy 是否永遠足夠？（ A 是 B 否 ）
3. Precision 關心預測為正時有多少是真的嗎？（ A 是 B 否 ）
4. Recall 關心實際正類找出多少嗎？（ A 是 B 否 ）
5. 預測路徑從哪裡開始？（ A 樹根 B 葉子 ）

答案：1-A 2-B 3-A 4-A 5-A

預測前提

新資料欄位必須與訓練資料一致

輸出內容

預測類別、機率或信心及判斷路徑

實務界線

預測支援決策，不直接取代決策

新資料的格式一致

第三節 02/11

欄位名稱

必須與訓練時使用的特徵相同

資料型態

數值與類別格式不能任意改變

前處理

缺失值與類別編碼要採相同規則

常見錯誤

訓練與預測使用不同單位或期間

未知客戶預測範例

第三節 03/11

輸入資料

新客戶的 R、F、M

模型運作

依節點條件選擇分枝

輸出類別

預測為高價值或低價值

後續工作

等實際結果出現後再核對

機率用途

表達模型對各類別的相對信心

門檻設定

可依業務風險調整分類門檻

不能誤解

80% 不代表個案一定會發生

校準需求

預測機率要與實際發生率比較

批次預測

定期對一批客戶或案件評分

即時預測

事件發生時立即輸入模型

選擇依據

決策時效、系統成本與資料可用性

共同要求

輸入資料與模型版本都要可追蹤

低風險行動

提供服務提醒或人工關懷

高影響行動

須增加人工覆核與申訴管道

避免自動化偏誤

人員不能只因模型輸出停止思考

記錄結果

保存最後決策及其理由

概念

新資料與訓練時的資料逐漸不同

可能原因

產品、客群、市場或詐欺手法改變

觀察訊號

錯誤率上升或特徵分布改變

處理方式

重新檢驗、更新資料並評估新模型

價值定義

高交易金額不代表完整的客戶關係

時間範圍

不同觀察期間可能得到不同類別

行動風險

不可因此忽略暫時低交易的客戶

使用原則

模型結果要與服務政策共同檢查

模型目的

說明要預測的類別與使用情境

測試表現

呈現混淆矩陣與重要錯誤

主要路徑

用白話整理關鍵分割條件

限制與監測

說明適用範圍、更新時點與覆核方式

Week 13 全週小結

第三節 10/11

資料流程

切分訓練與測試資料，避免資料洩漏

結果評估

依錯誤成本閱讀多項指標

未知預測

保持欄位與前處理規則一致

實務管理

監測模型漂移並保留人工責任

本節搶答題

第三節 11/11

5 分鐘 | 先作答，再核對答案

1. 新資料欄位是否要與訓練資料一致？(A 要 B 不用)

2. 80% 機率是否保證個案發生？(A 是 B 否)

3. 高影響決策是否要人工覆核？(A 要 B 不用)

4. 模型漂移代表資料可能改變嗎？(A 是 B 否)

5. 預測完成後是否仍要監測？(A 要 B 不用)

答案：1-A 2-B 3-A 4-A 5-A