

本週問題

大量文字如何整理成可分析的資料

學習主線

清理、斷詞、量化、解讀與應用

學習目標

能說明文字探勘流程並判讀結果

課程原則

重視概念與金融情境，程式只作示範

客服紀錄

電話摘要、聊天內容與服務備註

公開資訊

新聞、公告與法說會文字

顧客聲音

問卷開放題、申訴與社群留言

共同特性

內容豐富，但格式與用字不一致

文件 Document	一則新聞、一封申訴或一段對話
-------------	----------------

語料 Corpus	為分析目的蒐集的一組文件
-----------	--------------

詞彙 Vocabulary	語料中保留的不同詞語集合
---------------	--------------

分析單位	先決定文件邊界，結果才有一致意義
------	------------------

文字成為資料的流程

第一節 04/11

蒐集

確認來源、期間、欄位與使用權限

清理

統一格式並處理雜訊與缺漏

斷詞

把連續中文切成可分析的詞語

量化

轉為詞頻或重要性等數值特徵

格式統一

全形半形、大小寫與日期格式一致

雜訊處理

移除無意義標記、網址或重複內容

保留資訊

金額、否定詞與產品名稱可能很重要

原則

清理規則要配合分析目的並留下紀錄

困難來源

中文句子通常沒有天然空格

斷詞結果

把句子切成具有意義的詞語

不同工具

規則、詞典與統計模型可能產生不同結果

檢查方式

抽樣閱讀原文與斷詞結果

用途

讓系統辨識產品、機構與業務用語

例子

信用卡、房貸寬限期、違約交割

自訂詞

加入新商品、縮寫或常見合併詞

持續更新

金融用語與詐騙話術會隨時間改變

定義

高頻但對目前分析幫助較小的詞

常見例子

的、了、以及等功能詞

不可盲刪

不、未、無等否定詞會改變意思

實務做法

先看語料，再建立任務專用清單

同義表達

信用卡、卡片與本行卡可能指相近概念

標準化

把同義或不同寫法映射到共同名稱

保留差異

產品名稱或法律用語不可任意合併

判斷依據

業務規則與抽樣檢查共同決定

文字單位

文件組成語料，詞彙來自處理後內容

處理順序

蒐集、清理、斷詞後再量化

中文關鍵

專有詞庫與停用詞需要依任務調整

品質要求

所有處理規則都要可以追溯與檢查

本節搶答題

第一節 11/11

5 分鐘 | 先作答，再核對答案

1. 一則申訴可視為一份文件嗎？(A 可以 B 不可以)
2. 中文斷詞需要處理詞語邊界嗎？(A 需要 B 不需要)
3. 專有詞庫可加入金融產品名稱嗎？(A 可以 B 不可以)
4. 停用詞是否一律全部刪除？(A 是 B 否)
5. 否定詞可能改變句意嗎？(A 可能 B 不可能)

答案：1-A 2-A 3-A 4-B 5-A

分析問題

哪些詞常出現，哪些詞能區分文件

主要方法

詞頻、文件頻率與 TF-IDF

呈現工具

排序表、長條圖與文字雲

概念

計算某個詞在文件中出現的次數或比例

用途

快速掌握文件反覆談論的內容

限制

出現多不一定代表具有區辨力

比較注意

文件長度不同時可使用比例

概念

計算某個詞出現在多少份文件

高文件頻率

多數文件都會出現，可能較一般

低文件頻率

只出現在少數文件，可能更具特色

注意

過度罕見的詞也可能只是錯字或雜訊

目的	降低到處都出現之詞的影響
直覺	越少文件出現的詞，辨識力可能越高
搭配	通常與詞頻相乘形成 TF-IDF
限制	重要性來自統計，不等同業務重要性

高分情況

在本文件常見，但在其他文件較少見

低分情況

很少出現，或幾乎所有文件都出現

用途

找出文件代表詞並建立文字特徵

解讀

需回到原句確認詞語的實際語境

文件甲

多次提到海外刷卡與盜刷

文件乙

多次提到房貸利率與寬限期

共同詞

銀行、客戶可能在兩份文件都常見

TF-IDF效果

較能凸顯盜刷或寬限期等差異詞

詞袋模型 Bag of Words

第二節 07/11

表示方式

每份文件以各詞的出現數量表示

優點

簡單、可比較，也能投入分類模型

限制

通常忽略詞序與上下文

例子

沒有風險與風險不高可能被拆成相近詞

用途

用字體大小呈現詞頻或權重

適合

快速瀏覽與引發討論

限制

不利精確比較，也不呈現語境與否定

課堂定位

初步探索工具，不是分析結論

排序表

列出詞語、次數與權重

長條圖

比較前幾名詞語的差距

原文例句

確認詞語在何種情境出現

完整做法

數值結果與原文抽查一起呈現

詞頻

回答某個詞出現多少

文件頻率

回答某個詞出現在多少文件

TF-IDF

找出較能代表特定文件的詞

文字雲

方便瀏覽，但不能取代比較與解讀

本節搶答題

第二節 11/11

5 分鐘 | 先作答，再核對答案

1. 詞頻回答詞語出現多少嗎？(A 是 B 否)
2. DF 計算詞語出現在多少文件嗎？(A 是 B 否)
3. TF-IDF 高分通常代表較具文件特色嗎？(A 是 B 否)
4. 詞袋模型通常保留完整詞序嗎？(A 保留 B 不保留)
5. 文字雲可直接當分析結論嗎？(A 可以 B 不可以)

答案：1-A 2-A 3-A 4-B 5-B

應用主線

把文字轉成可支援決策的資訊

常見任務

分類、情緒判讀、主題整理與摘要

管理要求

驗證、隱私、公平與人工覆核

輸入

客服摘要、對話紀錄或申訴內容

輸出

問題類別、急迫程度或轉派單位

價值

協助案件分流並找出重複痛點

限制

高風險或語意不清案件仍需人工閱讀

資料

公司新聞、重大訊息與市場報導

分析

辨識公司、事件與可能影響方向

用途

協助研究人員篩選需要閱讀的內容

注意

新聞來源、發布時間與重複轉載要核對

資料

法說逐字稿、年報與研究摘要

比較

觀察不同期間常見主題與用詞變化

應用

協助整理管理階層關注事項

限制

文字語氣不能單獨證明公司實際表現

目標

判斷正向、負向或中性傾向

簡單方法

情緒詞典搭配規則計分

模型方法

以已標記文本學習分類

金融難點

反諷、否定與專業語境容易誤判

目的

從大量文件整理常見議題

例子

手續費、登入問題、詐騙與服務態度

使用方式

先看主題詞，再抽查代表文件

命名責任

主題名稱由分析者解讀，須說明依據

標準答案

由具業務知識的人員標記部分文件

切分資料

訓練與測試文件要分開

檢查指標

整體準確之外，也看各類別錯誤

錯誤分析

閱讀誤判原文，找出規則或資料問題

可能個資

姓名、帳號、聯絡方式與交易細節

最小使用

只保留完成任務所需欄位

權限管理

限制存取並記錄資料使用情形

外部工具

上傳文字前要確認契約與資料政策

偏誤來源

語料分布、標記方式與歷史處理差異

群體檢查

比較不同客群或語言表達的錯誤率

人工覆核

高影響案件由具權責人員確認

持續監測

新產品與新話術可能使模型失準

Week 15 全週小結

第三節 10/11

文字前處理

文件界定、清理、斷詞與詞庫調整

文字量化

詞頻、文件頻率與 TF-IDF

金融應用

客服、新聞、法說、情緒與主題分析

可信使用

回看原文，並兼顧驗證、隱私與公平

本節搶答題

第三節 11/11

5 分鐘 | 先作答，再核對答案

1. 客服文字可用於案件分類嗎？(A 可以 B 不可以)
2. 情緒分析容易受否定語影響嗎？(A 容易 B 不會)
3. 主題名稱需要分析者解讀嗎？(A 需要 B 不需要)
4. 測試文件應與訓練文件分開嗎？(A 應該 B 不必)
5. 高影響案件是否需要人工覆核？(A 需要 B 不需要)

答案：1-A 2-A 3-A 4-A 5-A